

**PROYECTO 2: ¿ESTÁN BIEN CALIBRADAS LAS CASAS DE APUESTAS?  
(PREMIER LEAGUE Y LA LIGA, 2012–2020)**

**INTEGRANTES:**

**ELÍAS JOSÉ PARRA ROYERO  
MARÍA MÓNICA MURILLO RINCÓN**

**DOCENTE:**

**ENRIQUE J. DE LA HOZ DOMÍNGUEZ**

**FACULTAD DE INGENIERÍA  
PROGRAMA DE INGENIERÍA INDUSTRIAL  
UNIVERSIDAD DEL MAGDALENA  
ESTADÍSTICA INDUSTRIAL  
SANTA MARTA, MAGDALENA  
2026**

## 1. Resumen

Este informe audita la calibración de las probabilidades implícitas en cuotas 1X2 (victoria local, empate, victoria visitante) de la Premier League (E0) y La Liga (SP1) entre las temporadas 2012/13 y 2019/20 (6.080 partidos validados). Se compararon cuatro series de cuotas de tres casas — Bet365 (B365), Pinnacle previo al cierre (PS) y al cierre (PSC), y William Hill (WH)— sobre una muestra común apareada de 6.074 partidos. La pregunta central es si, una vez removido el margen comercial, las probabilidades de las casas coinciden con las frecuencias observadas.

**Hallazgo principal:** las cuotas están bien calibradas en términos prácticos. La fiabilidad de Murphy no supera 0,0014 en la muestra común (como máximo 0,25 % del Brier) y las desviaciones medias entre probabilidad predicha y frecuencia observada van de 0,6 a 1,3 puntos porcentuales (pp) ponderadas por  $N$  (0,8 a 2,7 pp en versión simple), según el operador y el método de remoción del margen. Todas las casas mejoran el Brier de la frecuencia histórica en 12,0 % a 12,5 %. El **margen medio estimado** va de 2,24 % (PS) a 5,71 % (WH), de modo que el valor esperado de apostar de forma sostenida es negativo aun con calibración perfecta. Persisten matices: tras la corrección de Holm, Hosmer-Lemeshow rechaza en 3, 0 y 1 de 12 pruebas (multiplicativo, aditivo y Shin), y el sesgo favorito-longshot depende del método de reparto del margen. El estudio mide calibración marginal y no permite concluir eficiencia informativa del mercado.

## 2. Marco conceptual

### 2.1 Calibración de un pronóstico probabilístico

Un pronóstico probabilístico está calibrado si, entre los eventos a los que asigna probabilidad  $p$ , ocurre aproximadamente una fracción  $p$ . La calibración se distingue de la resolución (capacidad de separar situaciones distintas de la tasa base) y de la exactitud global, que se resume con reglas de puntuación estrictamente propias como el Brier (Brier, 1950) o el *Ranked Probability Score* (Epstein, 1969), en las que el pronosticador minimiza la penalización esperada reportando sus verdaderas creencias (Gneiting & Raftery, 2007). El Brier admite una descomposición en fiabilidad, resolución e incertidumbre (Murphy, 1973); la fiabilidad es la medida de descalibración. Gráficamente, la calibración se evalúa con diagramas de fiabilidad, que comparan la probabilidad predicha media con la frecuencia observada por intervalo.

### 2.2 Cuotas, probabilidades implícitas y margen

Para un partido con tres resultados (H, D, A) y cuotas decimales  $o$ , la probabilidad implícita bruta es  $\pi = 1/o$ . Como las casas cobran una comisión, la suma de las tres probabilidades brutas excede la unidad:

$$\pi_H + \pi_D + \pi_A = 1 + c, \quad c > 0$$

donde  $c$  es el margen (*overround*), expresado en este trabajo en puntos porcentuales. Si las cuotas se fijaran como  $o = 1/[(1 + c) \cdot p]$ , con  $p$  la probabilidad verdadera, el retorno esperado por unidad apostada sería  $p \cdot o - 1 = -c/(1 + c) < 0$  para cualquier resultado y cualquier reparto de la apuesta. Por eso el margen es la ventaja estructural del operador y una casa perfectamente calibrada sigue

siendo desfavorable para el apostador. Para auditar las probabilidades se debe remover el margen; el método elegido puede alterar las conclusiones, de ahí el análisis de sensibilidad (Štrumbelj, 2014; Shin, 1993).

### 2.3 Eficiencia del mercado y encuadre del proyecto

Desde la perspectiva de Fama (1970), un mercado es eficiente en su forma semifuerte si los precios incorporan la información pública disponible. Calibración marginal y eficiencia no son equivalentes: una casa puede estar calibrada y aun así ignorar información que permitiría predecir mejor. Este trabajo evalúa solo lo primero.

El proyecto es un ejercicio académico de evaluación de pronósticos, análogo a auditar un modelo de riesgo crediticio o de pronóstico del clima. **No es una guía ni una estrategia de apuestas.** En Colombia los juegos de suerte y azar están regulados por la Ley 643 de 2001 y administrados por Coljuegos, con prohibición para menores de 18 años; la ludopatía es una condición de salud tratable y existen canales de prevención y autoexclusión en [coljuegos.gov.co](http://coljuegos.gov.co) (Congreso de la República de Colombia, 2001).

**Preguntas de investigación.** *Principal:* ¿están bien calibradas las probabilidades implícitas de las casas una vez removido el margen? *Secundarias:* (a) ¿difiere la calidad probabilística entre casas, y mejoran las cuotas de cierre a las previas al cierre?; (b) ¿qué tanto depende el sesgo favorito-longshot del método usado para repartir el margen?

## 3. Datos

### 3.1 Fuente, alcance y operadores

Los datos provienen de Football-Data.co.uk (Buchdahl, s. f.). Se descargaron manualmente los 16 archivos CSV (E0 y SP1  $\times$  8 temporadas) porque la red institucional bloqueó el dominio durante el intento de descarga automática desde R; los archivos se guardaron en `data/raw/` y se renombraron con un script que identifica liga y temporada a partir de las columnas *Div* y *Date*, y estos datos fueron descargados el día 11 de septiembre en el horario de la tarde. El alcance (ligas, temporadas, operadores y parámetros) se controla desde `config.R`: 20 equipos por liga implican 380 partidos por liga-temporada y 6.080 en total.

**Operadores incluidos.** En este informe, "operador" designa una serie de cuotas; PS y PSC son la misma casa (Pinnacle) en dos momentos, por lo que las cuatro series corresponden a tres casas. El análisis principal usa B365, PS, PSC y WH, elegidos por tener cobertura casi completa (superior a 99 %) en todas las combinaciones liga-temporada. En football-data, PS corresponde a cuotas de Pinnacle previas al cierre (no necesariamente de apertura) y PSC a las de cierre. **Operadores excluidos.** Se detectaron 22 prefijos con las tres cuotas H/D/A: 16 prefijos de casas reales (que incluyen las series PS y PSC) y 6 agregados de mercado (Max, Avg, BbMx, BbAv y sus variantes de cierre). Los agregados se excluyeron como operadores porque toman el máximo o el promedio por resultado entre varias casas, no son el precio de ninguna casa y generan márgenes

artificialmente bajos o negativos (por ejemplo,  $-0,87\%$  en MaxC y  $-0,21\%$  en BbMx); los 16 prefijos de casas reales presentan márgenes de  $2,24\%$  a  $6,96\%$ .

**Advertencia sobre Pinnacle.** Football-Data advierte que las cuotas de Pinnacle posteriores al 23 de julio de 2025 son poco confiables. Aplica en forma preventiva, no a esta muestra: el último partido analizado es del 26 de julio de 2020, por lo que ninguna fila de PS o PSC se ve afectada. Aun así, el flujo anula (NA) las cuotas PS/PSC desde esa fecha para proteger futuras ampliaciones del alcance.

### 3.2 Inventario de cobertura y validaciones

**Tabla 1.** Cobertura de los operadores principales (6.080 partidos validados)

| Operador | Partidos con cuota | Total de partidos | Cobertura media (%) | Cobertura mínima (%) |
|----------|--------------------|-------------------|---------------------|----------------------|
| B365     | 6.080              | 6.080             | 100,0               | 100,0                |
| PS       | 6.075              | 6.080             | 99,9                | 99,5                 |
| PSC      | 6.079              | 6.080             | 100,0               | 99,7                 |
| WH       | 6.080              | 6.080             | 100,0               | 100,0                |

*Nota.* Cobertura mínima: menor cobertura en una combinación liga-temporada. Fuente: inventario\_cobertura.csv.

**Validaciones realizadas** (Fase 1): (i) consistencia del resultado (FTR) con el marcador; (ii) anulación (NA) de cuotas imposibles ( $\leq 1$ ) solo en prefijos con el trío H/D/A completo; (iii) búsqueda de duplicados exactos; (iv) parseo de fechas en los formatos dd/mm/aa y dd/mm/aaaa; (v) guarda temporal de Pinnacle; (vi) marca de los partidos posteriores a la reanudación por COVID-19 y (vii) inventario de cobertura por operador, liga y temporada. Se leyeron 6.081 filas y se descartó una, un registro totalmente en blanco de la Premier League 2014/15 sin fecha ni equipos (registrado con su motivo en filas\_descartadas.csv), con lo que la base quedó en exactamente 6.080 partidos, igual al fixture esperado.

**Muestra común apareada.** Las comparaciones entre operadores se restringen a los partidos con cuotas completas en los cuatro operadores simultáneamente: 6.074 partidos (99,90 % de 6.080; 3.040 de E0 y 3.034 de SP1), lo que evita sesgos de selección y permite las pruebas apareadas. Los 200 partidos de la muestra común de la temporada 2019/20 posteriores a la reanudación por COVID-19 (a puerta cerrada; 202 en la base completa) se marcan para un análisis de sensibilidad; las fechas de reanudación usadas, aproximadas y definidas en config.R, son 17/06/2020 para E0 y 11/06/2020 para SP1.

## 4. Metodología

### 4.1 Conversión y remoción del margen

Las cuotas se convierten a probabilidades brutas  $\pi = 1/o$  y el margen se calcula como  $c = \Sigma \pi - 1$ . Se aplican tres métodos de remoción del margen a los operadores principales; el multiplicativo es el esquema de referencia y los otros dos sirven para evaluar la sensibilidad de las conclusiones:

- **Multiplicativo (proporcional):**  $p_j = \pi_j / \Sigma \pi_k$ . Reparte el margen en proporción al tamaño de cada probabilidad.
- **Aditivo:**  $p_j = \pi_j - c/3$ . Reparte el margen en partes iguales. En mercados muy desbalanceados puede producir una probabilidad negativa; en ese caso las tres probabilidades del partido se anulan (NA) y se registran, porque truncar a cero rompería la suma a 1. Ocurrió en una sola fila de William Hill.
- **Shin (1993):** modela una proporción  $z$  de apostadores informados (*insiders*) y estima las probabilidades como  $p_j = [\sqrt{(z^2 + 4(1-z)\pi_j^2/s)} - z] / [2(1-z)]$ , con  $s = \Sigma \pi$ , donde  $z$  se obtiene numéricamente (uniroot) de modo que  $\Sigma p_j = 1$ . Por construcción asigna más margen a los resultados improbables que el método multiplicativo. En la muestra común no hubo fallos de convergencia.

### 4.2 Esquema de agrupamiento

Las curvas de calibración usan **10 intervalos de igual ancho** en  $[0, 1]$ . Este esquema permite comparar todos los operadores en la misma escala de probabilidad y corresponde al diagrama de fiabilidad estándar; su costo es que las probabilidades de empate se concentran en pocos intervalos (4 intervalos ocupados para D frente a 9–10 para H y A) y que los extremos quedan poco poblados. Por ello los intervalos con menos de 30 observaciones se marcan como poco confiables, no entran en los contrastes de tendencia y las medidas resumen se ponderan por  $N$ . La sensibilidad al agrupamiento se evalúa con 5, 10 y 20 intervalos, y el análisis favorito-longshot usa 20. Cada intervalo lleva intervalos de confianza al 95 % de Wilson y bootstrap percentil por partido (500 réplicas).

### 4.3 Reglas de puntuación

Se usan dos reglas estrictamente propias. El **Brier multiclase** es  $BS = (1/N) \cdot \Sigma_i \Sigma_j (p_{ij} - y_{ij})^2$ , con línea base uniforme  $2/3 \approx 0,6667$ . El **RPS**, que respeta el orden  $H < D < A$ , es  $RPS = \frac{1}{2}[(p_H - y_H)^2 + (p_H + p_D - y_H - y_D)^2]$ , con línea base uniforme 0,2373. Ambas se comparan contra la frecuencia histórica (predicción constante igual a la tasa marginal  $H \approx 46,2\%$ ,  $D \approx 24,3\%$ ,  $A \approx 29,5\%$ ), calculada con la propia muestra. La **descomposición de Murphy** ( $BS = \text{fiabilidad} - \text{resolución} + \text{incertidumbre}$ ) se calcula con 10 intervalos; al discretizar queda un término intra-intervalo, de modo que las casas se comparan con el Brier real y la descomposición se usa solo para aislar la fiabilidad.

### 4.4 Pruebas empleadas y su pertinencia ante la dependencia

Los datos presentan tres fuentes de dependencia que condicionan la elección de las pruebas:

1. **Las tres filas de un partido (H, D, A) suman 1.** Apilarlas en una sola prueba viola la independencia del chi-cuadrado. Por eso Hosmer-Lemeshow se corre por separado para cada resultado ( $4 \text{ operadores} \times 3 \text{ resultados} = 12 \text{ pruebas por método}$ ), de modo que cada partido aporta una observación binaria. Como las probabilidades son exógenas (las emite el mercado, no un modelo ajustado a esta muestra), los grados de libertad son  $gl = G$  (intervalos ocupados); se guardan también los valores con  $G - 1$  y  $G - 2$ . Dentro de cada método se aplica Holm y se reporta siempre la magnitud de la desviación en pp (simple y ponderada por N) junto con el valor p (Hosmer et al., 2013). La pendiente de calibración logística,  $\text{logit}(P) = \alpha + \beta \cdot \text{logit}(p)$ , usa errores estándar robustos por clúster de partido (estimador sándwich).
2. **Las casas cotizan los mismos partidos.** Las muestras no son independientes, así que se emplean pruebas apareadas: Friedman como prueba global y Wilcoxon de rangos con signo apareado con Holm como contraste post hoc, sobre B365, PS y WH. PSC se excluye de esta familia porque PS y PSC son la misma casa en dos momentos, y esa comparación se hace aparte (Wilcoxon apareado). Como Wilcoxon contrasta pseudomedianas y trata los partidos como independientes, se agregan intervalos bootstrap por bloques (liga-temporada-mes, 500 réplicas) para la diferencia media de Brier.
3. **Dependencia entre partidos de una misma jornada o temporada.** Se aborda solo parcialmente con el bootstrap por bloques y con los errores por clúster, y se declara como limitación. La comparación entre ligas, cuyas muestras sí son distintas, usa Mann-Whitney con intervalo bootstrap y Holm.

Las comparaciones múltiples se controlan con Holm en cada familia (Hosmer-Lemeshow, favorito-longshot y comparación de Brier entre operadores). Se evalúa además la sensibilidad al método de margen, al número de intervalos y a la exclusión de los partidos posteriores a la reanudación por COVID-19, con un control por remoción aleatoria del mismo número de partidos (200 réplicas). **Reproducibilidad:** el flujo completo se ejecuta con `run_all.R`, sus parámetros viven en `config.R`, el entorno se fija con `renv` y la semilla del bootstrap es 20262.

## 5. Resultados

### 5.1 Distribución del margen


**Tabla 2.** Margen medio y parámetro de insiders (*z* de Shin) por operador

| Operador | Margen medio (%) | Mediana (%) | Desv. est. (%) | <i>z</i> de Shin |
|----------|------------------|-------------|----------------|------------------|
| PS       | 2,24             | 2,03        | 0,22           | 0,0113           |
| PSC      | 2,26             | 2,05        | 0,28           | 0,0114           |
| B365     | 4,42             | 5,04        | 0,76           | 0,0224           |
| WH       | 5,71             | 6,05        | 0,64           | 0,0290           |

*Nota.* Medias ponderadas por número de partidos. Fuente: `distribucion_margen.csv`.

Pinnacle cobra los márgenes más bajos (2,24 % en PS y 2,26 % en PSC), seguido de Bet365 (4,42 %) y William Hill (5,71 %); el parámetro  $z$  de Shin sigue el mismo orden. El margen depende también de la liga: la mayor diferencia entre La Liga y la Premier League es la de B365 (5,56 % frente a 3,29 %, 2,27 pp), mientras que en PS, PSC y WH es de 0,10 a 0,19 pp (Tabla 9). La Figura 1 muestra su evolución por temporada. Las probabilidades que resultan de los tres métodos difieren poco: la diferencia media por resultado va de 0,05 a 1,01 pp y la máxima observada es de 4,65 pp (William Hill, victoria visitante, multiplicativo frente a aditivo).


**Figura 1.** *Evolución del margen medio por temporada, operador y liga*



## 5.2 Curvas de calibración

Las curvas siguen de cerca la diagonal de calibración perfecta en los cuatro operadores (Figura 2). Las desviaciones visibles se concentran en los intervalos de probabilidad alta (aproximadamente 65 % a 85 %), donde la frecuencia observada queda ligeramente por encima de la predicha, y en el último intervalo ( $\approx 90$  %), poco poblado, con intervalos de confianza amplios, sobre todo en William Hill. Los intervalos de Wilson y bootstrap por partido son de amplitud similar en los intervalos centrales.

**Figura 2.** Curvas de calibración (normalización multiplicativa) con intervalos de Wilson (azul) y bootstrap por partido (rojo) al 95 %



*Nota.* Puntos huecos: intervalos con menos de 30 observaciones. El tamaño del punto es proporcional a N.

### 5.3 Desviaciones por intervalo y prueba de Hosmer-Lemeshow

Sin ajuste se rechaza la calibración perfecta en 4, 5 y 4 de las 12 pruebas por método (multiplicativo, aditivo, Shin); tras Holm quedan 3, 0 y 1. Los rechazos con Holm son PS-D ( $p = 0,021$ ), WH-H ( $p = 0,034$ ) y WH-D ( $p = 0,032$ ) con el método multiplicativo, y WH-H ( $p = 0,032$ ) con Shin. Las combinaciones que rechazan sin ajuste con los tres métodos son PS-D, WH-H y WH-D. En Pinnacle al cierre ninguna prueba rechaza ( $p$  sin ajustar = 0,086 en H, 0,062 en D y 0,938 en A, multiplicativo). Con aditivo y Shin, PSC-D sí rechaza sin ajuste ( $p = 0,041$  y 0,032), pero no tras Holm. Para victoria visitante el menor valor  $p$  sin ajustar entre operadores y métodos es 0,621, lo que indica ausencia de evidencia de descalibración, no calibración perfecta.

La relevancia práctica es menor que la significancia: la desviación media absoluta va de 0,97 a 3,35 pp (simple) y de 0,65 a 2,37 pp (ponderada por N) según operador, resultado y método; los rechazos con mayor desviación ponderada son WH-H (2,33 pp) y WH-D (1,68 pp) en el método multiplicativo. En algunas pruebas un intervalo tiene frecuencia esperada menor que 5, donde la aproximación chi-cuadrado es menos fiable.

**Tabla 3.** Valor  $p$  de Hosmer-Lemeshow ajustado por Holm, según método de remoción del margen

| Operador | Resultado | Multiplicativo | Aditivo | Shin  |
|----------|-----------|----------------|---------|-------|
| B365     | H         | 0,424          | 0,454   | 0,581 |
| B365     | D         | 0,424          | 0,575   | 0,581 |

| Operador | Resultado | Multiplicativo | Aditivo | Shin  |
|----------|-----------|----------------|---------|-------|
| B365     | A         | 1,000          | 1,000   | 1,000 |
| PS       | H         | 0,673          | 0,398   | 0,520 |
| PS       | D         | 0,021          | 0,300   | 0,256 |
| PS       | A         | 1,000          | 1,000   | 1,000 |
| PSC      | H         | 0,514          | 0,450   | 0,581 |
| PSC      | D         | 0,434          | 0,365   | 0,318 |
| PSC      | A         | 1,000          | 1,000   | 1,000 |
| WH       | H         | 0,034          | 0,061   | 0,032 |
| WH       | D         | 0,032          | 0,338   | 0,396 |
| WH       | A         | 1,000          | 1,000   | 1,000 |

*Nota.* 12 pruebas por método (4 operadores  $\times$  3 resultados),  $\alpha = 0,05$ . Fuente: hosmer\_lemeshow.csv.

#### 5.4 Reglas de puntuación frente a líneas base

**Tabla 4.** *Brier y RPS por operador frente a la línea base de frecuencia histórica (N = 6.074)*

| Operador | Brier  | Mejora vs. frecuencia (%) | Mejora vs. uniforme (%) | RPS    | Mejora vs. frecuencia (%) | Mejora vs. uniforme (%) |
|----------|--------|---------------------------|-------------------------|--------|---------------------------|-------------------------|
| PSC      | 0,5601 | 12,53                     | 15,99                   | 0,1906 | 16,51                     | 19,69                   |
| PS       | 0,5621 | 12,22                     | 15,68                   | 0,1916 | 16,09                     | 19,29                   |
| B365     | 0,5626 | 12,14                     | 15,61                   | 0,1917 | 16,01                     | 19,22                   |
| WH       | 0,5633 | 12,04                     | 15,51                   | 0,1918 | 15,97                     | 19,17                   |

*Nota.* Líneas base: frecuencia histórica (Brier 0,6403; RPS 0,2283) y uniforme (Brier 0,6667; RPS 0,2373). Normalización multiplicativa.

Todos los operadores superan ambas líneas base, con mejoras de Brier de 12,0 % a 12,5 % frente a la frecuencia histórica y de 15,5 % a 16,0 % frente a la uniforme. La descomposición de Murphy confirma que el error de calibración es mínimo: la fiabilidad no supera 0,00141 (WH) y representa como máximo 0,25 % del Brier en la muestra común (por liga llega a 0,00207, en WH-La Liga, cerca de 0,37 %; Tabla 10), mientras que la resolución (0,076–0,079) y la incertidumbre (0,64035) explican el resto.

**Tabla 5.** *Descomposición de Murphy del Brier (normalización multiplicativa)*

| Operador | Fiabilidad | Resolución | Incertidumbre | Brier por descomposición | Brier real | Término intra-intervalo |
|----------|------------|------------|---------------|--------------------------|------------|-------------------------|
| B365     | 0,00082    | 0,07635    | 0,64035       | 0,5648                   | 0,5626     | –0,0022                 |
| PS       | 0,00101    | 0,07736    | 0,64035       | 0,5640                   | 0,5621     | –0,0019                 |

| Operador | Fiabilidad | Resolución | Incertidumbre | Brier por descomposición | Brier real | Término intra-intervalo |
|----------|------------|------------|---------------|--------------------------|------------|-------------------------|
| PSC      | 0,00078    | 0,07933    | 0,64035       | 0,5618                   | 0,5601     | -0,0017                 |
| WH       | 0,00141    | 0,07631    | 0,64035       | 0,5655                   | 0,5633     | -0,0022                 |

*Nota.* El término intra-intervalo (entre -0,0022 y -0,0017) es del mismo orden que las diferencias de Brier entre casas (0,0005 a 0,0012); por eso las casas se comparan con el Brier real.

**Comparación entre casas.** Todas cotizan los mismos 6.074 partidos. La prueba de Friedman rechaza que B365, PS y WH tengan el mismo Brier por partido ( $\chi^2 = 253,54$ ; gl = 2;  $p = 8,79 \times 10^{-56}$ ). El orden por Brier (menor es mejor) es PS < B365 < WH, igual con los tres métodos de margen. Wilcoxon con Holm es significativo en las tres comparaciones, pero la magnitud es modesta (diferencias de 0,0005 a 0,0012; mejoras de 0,09 % a 0,21 %) y en B365 frente a WH el intervalo bootstrap por bloques de la diferencia media incluye el cero, por lo que esa diferencia no es firme.

**Tabla 6.** *Contrastes apareados entre casas: diferencia de Brier e intervalos bootstrap por bloques*

| Comparación | Brier Op1 | Brier Op2 | Diferencia | IC boot. inf. | IC boot. sup. | Mejora (%) | Incluye 0 |
|-------------|-----------|-----------|------------|---------------|---------------|------------|-----------|
| B365 vs PS  | 0,5626    | 0,5621    | 0,00050    | 0,00002       | 0,00092       | -0,09      | No        |
| B365 vs WH  | 0,5626    | 0,5633    | -0,00067   | -0,00138      | 0,00003       | 0,12       | Sí        |
| PS vs WH    | 0,5621    | 0,5633    | -0,00117   | -0,00201      | -0,00038      | 0,21       | No        |

*Nota.* Diferencia = Brier Op1 – Brier Op2. Wilcoxon con Holm: significativo en las tres comparaciones (valores p ajustados:  $2,2 \times 10^{-9}$  en B365 vs PS,  $5,0 \times 10^{-15}$  en B365 vs WH y  $1,4 \times 10^{-22}$  en PS vs WH).

## 5.5 Desviaciones sistemáticas

**Sesgo favorito-longshot.** Un sesgo corresponde a  $\beta > 1$ : los longshots ocurren menos de lo predicho y los favoritos más. Con el método multiplicativo los favoritos se desvían de +1,29 a +2,66 pp y los longshots de -0,97 a -0,58 pp, y las pendientes van de 1,038 a 1,106; tras Holm solo WH es robusto ( $\beta = 1,106$ ;  $p$  Holm = 0,0056). Con Shin las pendientes van de 1,009 a 1,045 y ningún operador es robusto. La conclusión depende, por tanto, de cómo se reparte el margen, y estos datos no permiten decidir cuál método refleja mejor la realidad. Al estimar  $\beta$  por resultado, H y A van de 0,986 a 1,071, mientras que el empate sube a 1,227–1,386 (tras Holm solo sobrevive WH-multiplicativo-D,  $\beta = 1,386$ ;  $p$  Holm = 0,044): parte del sesgo conjunto aparente proviene del empate, cuyas probabilidades están comprimidas en un rango estrecho.

**Tabla 7.** *Pendiente de calibración logística ( $\beta$ ) y error estándar robusto por clúster de partido*

| Operador | Método | Spearman ( $\rho$ ) | $\beta$ | EE( $\beta$ ) | p ( $\beta = 1$ ) | p Holm | Sesgo robusto |
|----------|--------|---------------------|---------|---------------|-------------------|--------|---------------|
| B365     | Mult.  | 0,802               | 1,055   | 0,029         | 0,060             | 0,420  | No            |

| Operador | Método | Spearman ( $\rho$ ) | $\beta$ | EE( $\beta$ ) | p ( $\beta = 1$ ) | p Holm | Sesgo robusto |
|----------|--------|---------------------|---------|---------------|-------------------|--------|---------------|
| PS       | Mult.  | 0,546               | 1,038   | 0,029         | 0,188             | 0,781  | No            |
| PSC      | Mult.  | 0,363               | 1,041   | 0,029         | 0,153             | 0,781  | No            |
| WH       | Mult.  | 0,688               | 1,106   | 0,031         | 0,0007            | 0,006  | Sí            |
| B365     | Shin   | 0,098               | 1,009   | 0,028         | 0,758             | 1,000  | No            |
| PS       | Shin   | 0,232               | 1,014   | 0,028         | 0,628             | 1,000  | No            |
| PSC      | Shin   | -0,028              | 1,016   | 0,028         | 0,566             | 1,000  | No            |
| WH       | Shin   | 0,360               | 1,045   | 0,030         | 0,130             | 0,781  | No            |

*Nota.* Holm aplicado sobre 8 casos (4 operadores  $\times$  2 métodos). Spearman calculado sobre 18–19 intervalos con  $N \geq 30$ ; es la evidencia más frágil de las dos.

**Cuotas previas al cierre frente a cuotas de cierre en Pinnacle.** Las cuotas de cierre superan a las previas al cierre en Brier (diferencia -0,00202; IC bootstrap [-0,00309; -0,00093]; mejora de 0,36 %; Wilcoxon  $p = 7,3 \times 10^{-6}$ ) y en RPS (diferencia -0,00096; IC [-0,00145; -0,00046]; mejora de 0,50 %;  $p = 1,1 \times 10^{-5}$ ). La ganancia es estadísticamente clara pero pequeña.

## 5.6 Análisis de sensibilidad entre métodos

**Tabla 8.** Brier y desviación de calibración según el método de remoción del margen

| Operador | Brier (M / A / S)        | Desv. ponderada, pp (M / A / S) | Desv. simple, pp (M / A / S) |
|----------|--------------------------|---------------------------------|------------------------------|
| B365     | 0,5626 / 0,5625 / 0,5625 | 0,65 / 0,68 / 0,71              | 1,62 / 0,77 / 0,89           |
| PS       | 0,5621 / 0,5620 / 0,5620 | 0,60 / 0,67 / 0,64              | 1,05 / 0,79 / 0,87           |
| PSC      | 0,5601 / 0,5600 / 0,5600 | 0,68 / 0,57 / 0,57              | 1,51 / 1,00 / 1,21           |
| WH       | 0,5633 / 0,5628 / 0,5628 | 1,32 / 0,74 / 0,89              | 2,72 / 1,02 / 1,27           |

*Nota.* M = multiplicativo, A = aditivo, S = Shin. Desviaciones medias absolutas con 10 intervalos de igual ancho.

Las conclusiones sobre **qué casa predice mejor** son solo parcialmente robustas al método. El orden  $PS < B365 < WH$  se mantiene con los tres métodos, pero la separación entre casas no siempre supera la variación que introduce el método: el Brier de una casa cambia como máximo 0,0005 entre métodos (WH). La ventaja de PS sobre WH (0,0008 a 0,0012 según el método) supera esa variación. En cambio, la diferencia entre B365 y WH baja de 0,0007 (multiplicativo) a 0,0003 (aditivo y Shin), y la de B365 frente a PS (0,0005) es del mismo orden que la variación por método; además, en los contrastes con bootstrap por bloques (Tabla 6, método multiplicativo) la primera incluye el cero y la segunda lo excluye por muy poco. Solo la ventaja de PS sobre WH puede considerarse firme frente a la elección del método. En cambio, las conclusiones sobre **cuánto se desvía** una casa dependen del método: en WH la desviación pasa de 1,02 a 2,72 pp (simple) y de 0,74 a 1,32 pp (ponderada), los rechazos de Hosmer-Lemeshow con Holm son 3, 0 y 1, y el sesgo favorito-longshot solo es robusto con el método multiplicativo.

## 5.7 Análisis complementarios: COVID-19 y comparación entre ligas

**Partidos posteriores a la reanudación por COVID-19.** Al excluir los 200 partidos, el Brier cambia entre  $-0,0003$  y  $-0,0001$  y los rechazos con Holm pasan de 3 a 2 (multiplicativo), de 0 a 0 (aditivo) y de 1 a 0 (Shin); dejan de rechazar WH-H en el método multiplicativo y en Shin. En esos 200 partidos la victoria local fue de 43,5 % frente a una probabilidad implícita media de 41,8 % a 42,3 % (desviación de +1,18 a +1,65 pp); ninguna desviación es distinta de cero ( $p$  de 0,607 a 0,711) y en el resto de la muestra la desviación también es positiva (0,50 a 1,52 pp) y en WH es significativa (1,52 pp;  $p = 0,011$ , sin ajustar), lo que indica que la desviación de WH en victoria local no es exclusiva de esos partidos. Como control, al quitar 200 partidos al azar en 200 réplicas el rechazo se mantiene en 53 % a 81 % de las réplicas según la prueba; en WH-H multiplicativo se pierde en 47 % de ellas. La pérdida del rechazo al excluir COVID es, por tanto, comparable a la que produce una remoción aleatoria y no basta para atribuirla a un efecto específico de esos partidos.

**Tabla 9.** Margen medio por liga y diferencia de Brier entre ligas

| Operador | Margen E0 (%) | Margen SP1 (%) | Dif. margen (pp) | Brier E0 | Brier SP1 | IC boot. dif. Brier | p Holm |
|----------|---------------|----------------|------------------|----------|-----------|---------------------|--------|
| B365     | 3,29          | 5,56           | 2,27             | 0,5627   | 0,5625    | $[-0,0174; 0,0179]$ | 1,000  |
| PS       | 2,19          | 2,30           | 0,11             | 0,5623   | 0,5620    | $[-0,0169; 0,0183]$ | 1,000  |
| PSC      | 2,21          | 2,31           | 0,10             | 0,5611   | 0,5591    | $[-0,0213; 0,0150]$ | 1,000  |
| WH       | 5,61          | 5,80           | 0,19             | 0,5642   | 0,5623    | $[-0,0181; 0,0129]$ | 1,000  |

*Nota.* E0 = Premier League; SP1 = La Liga. Valor  $p$  de Mann-Whitney con Holm (0,809 a 0,960 sin ajustar). Los márgenes usan todos los partidos con cuota de cada operador (en SP1, 3.035 en PS y 3.039 en PSC); el Brier usa la muestra común (3.040 en E0 y 3.034 en SP1).

**Comparación entre ligas.** No se detecta diferencia de Brier entre ligas en ningún operador ( $p$  Holm = 1,000), pero los intervalos bootstrap de la diferencia de Brier son anchos (de  $-0,0213$  a  $0,0183$ ), muy superiores a las diferencias de 0,0005–0,0012 observadas entre casas; la ausencia de evidencia no demuestra que las ligas sean iguales.

Como el Brier también depende de la dificultad intrínseca de cada liga, la Tabla 10 reporta la fiabilidad de Murphy y la desviación ponderada por liga. La fiabilidad es mayor en La Liga en las cuatro series (0,00156 a 0,00207 frente a 0,00113 a 0,00177 en la Premier League), mientras que la desviación ponderada es menor en La Liga en B365, PS y WH e igual en PSC. Con la mitad de los partidos por liga, la fiabilidad estimada puede ser mayor por el menor tamaño muestral, y estas diferencias no se contrastaron formalmente, por lo que no se interpretan como diferencia de calibración entre ligas.

**Tabla 10.** *Fiabilidad de Murphy y desviación ponderada por liga (muestra común, normalización multiplicativa)*

| Operador | Fiabilidad E0 | Fiabilidad SP1 | Desv. pond. E0 (pp) | Desv. pond. SP1 (pp) |
|----------|---------------|----------------|---------------------|----------------------|
| B365     | 0,00113       | 0,00182        | 0,91                | 0,80                 |
| PS       | 0,00152       | 0,00190        | 1,05                | 0,56                 |
| PSC      | 0,00120       | 0,00156        | 0,90                | 0,90                 |
| WH       | 0,00177       | 0,00207        | 1,53                | 1,29                 |

*Nota.* Fiabilidad de Murphy con 10 intervalos de igual ancho; desviación media absoluta ponderada por N. E0 = Premier League; SP1 = La Liga. Fuente: `calibracion_por_liga.csv`.

## 6. Discusión

### 6.1 Calibración y eficiencia del mercado

Los resultados indican que las cuotas de las cuatro casas están bien calibradas en términos prácticos: la descalibración pura explica a lo sumo 0,25 % del error cuadrático en la muestra común, las curvas siguen la diagonal y las desviaciones medias ponderadas son de 0,6 a 1,3 pp. Esto es compatible con un mercado que traduce razonablemente bien la información disponible. Es compatible, además, con la jerarquía observada: Pinnacle, de menor margen y menor  $z$  de Shin, obtiene el mejor Brier, y sus cuotas de cierre mejoran a las previas al cierre en 0,36 %, como cabría esperar si entre ambos momentos se incorpora información nueva. Sin embargo, el diseño mide calibración marginal de las cuotas 1X2, no evalúa si existe información adicional que permitiría predecir mejor y, por tanto, **no permite concluir eficiencia informativa** del mercado en el sentido de Fama (1970).

### 6.2 Significancia estadística frente a relevancia práctica

Con 6.074 partidos, diferencias muy pequeñas resultan estadísticamente detectables. Las diferencias de Brier entre casas (0,0005 a 0,0012; 0,09 % a 0,21 %) son significativas con Wilcoxon, pero una de ellas (B365 frente a WH) no es firme cuando se considera la dependencia por bloques. De forma análoga, los pocos rechazos de Hosmer-Lemeshow que sobreviven a Holm corresponden a desviaciones ponderadas de 1,1 a 2,4 pp y dependen del método de margen (3, 0 y 1 rechazos). Lo que sí es grande en términos prácticos es el margen: entre 2,24 % y 5,71 %, equivalente, bajo calibración perfecta, a un retorno esperado de  $-c/(1 + c)$ , es decir, aproximadamente -2,2 % a -5,4 % por unidad apostada. Ese costo supera con holgura las desviaciones de calibración halladas, de modo que ninguna de ellas, aunque fuera real, sería explotable frente a un margen de ese tamaño. Esta comparación es aritmética y no constituye recomendación de apuesta.

### 6.3 Lectura prudente de los matices

El **sesgo favorito-longshot** aparece de forma robusta únicamente en William Hill con el método multiplicativo y desaparece con Shin. Como cada método asume un reparto distinto del margen,

los datos no permiten afirmar que el sesgo sea una ineficiencia del mercado ni que sea solo un artefacto de la normalización; lo que muestran es cuánto del sesgo aparente es sensible al método. Que el empate concentre las pendientes más altas (1,23–1,39) indica que parte del sesgo conjunto proviene de ese resultado. Respecto de **COVID-19**, la ventaja local observada en los 200 partidos a puerta cerrada no difiere de forma detectable de la implícita, y la pérdida de algunos rechazos al excluirlos es del orden de la que produce una remoción aleatoria: el efecto no está demostrado. Por último, la ausencia de diferencias entre ligas debe leerse con los intervalos anchos en la mano, como ausencia de evidencia y no como igualdad.

## 7. Limitaciones

1. **Dependencia entre observaciones.** Los errores por clúster de partido y el bootstrap por bloques (liga-temporada-mes) corrigen la dependencia entre las tres filas de un partido y entre partidos de un mismo mes, pero no toda la dependencia posible entre partidos de una misma jornada, equipo o temporada. Las pendientes de los operadores se evalúan sobre los mismos partidos y no son réplicas independientes.
2. **Comparaciones múltiples.** Holm se aplica dentro de cada familia, pero el número total de pruebas del estudio es grande; los hallazgos con  $p$  Holm cercano a 0,05 (PS-D 0,021; WH-D 0,032; WH-H 0,034) deben leerse con cautela. Con muestras grandes, además, diferencias mínimas resultan significativas.
3. **Cobertura desigual.** PS tiene 6.075 partidos con cuota y PSC 6.079, frente a 6.080 de B365 y WH; la muestra común de 6.074 descarta 6 partidos, lo que es despreciable pero implica que los resultados valen para partidos con las cuatro cuotas. Los márgenes de operadores con cobertura distinta no son comparables entre sí, y solo se analizan tres casas (cuatro series de cuotas) de los 16 prefijos de casas reales identificados.
4. **Sensibilidad al agrupamiento.** Con intervalos de ancho fijo, el empate ocupa solo 4 intervalos y hay hasta un intervalo con menos de 30 partidos en un mismo operador (mínimo de 7); en algunas pruebas hay intervalos con frecuencia esperada menor que 5. La desviación media simple, que pesa igual a intervalos poco poblados, tiende a exagerar frente a la ponderada. Esquemas con pocos intervalos pueden enmascarar desviaciones sutiles.
5. **Sensibilidad al método de normalización.** Las conclusiones sobre la magnitud de la desviación y el sesgo favorito-longshot cambian con el método (por ejemplo, 3, 0 y 1 rechazos de Hosmer-Lemeshow). El método aditivo anuló una fila de William Hill por probabilidad negativa. Las líneas base de frecuencia se calculan con la propia muestra y quedan ligeramente favorecidas.
6. **Alcance y datos.** Los resultados corresponden a dos ligas muy líquidas entre 2012/13 y 2019/20, un período que incluye la primera fase de la pandemia; ligas de menor liquidez pueden mostrar márgenes y calibración distintos. PS no es una cuota de apertura sino previa al cierre, y las fechas de reanudación por COVID-19 son aproximadas (config.R).

**Lo que el diseño no permite concluir.** (i) Eficiencia informativa del mercado, porque solo se evalúa calibración marginal; (ii) rentabilidad o estrategia de apuestas, pues el margen implica valor esperado negativo; (iii) un efecto causal de la ausencia de público sobre la ventaja local; (iv) si el sesgo favorito-longshot es una ineficiencia real o un artefacto del reparto del margen; y (v) igualdad entre ligas a partir de una prueba no significativa.

## 8. Uso de inteligencia artificial

Se emplearon Claude (Anthropic) y Antigravity (Google DeepMind) como apoyo en programación en R y estructuración del análisis, entre el 8 de septiembre y el 3 de octubre de 2026 (21 interacciones registradas). Cada fórmula, línea de código e interpretación se auditó contra los datos o la lógica estadística del proyecto, y varias propuestas se rechazaron o corrigieron:

- **Independencia en Hosmer-Lemeshow:** la IA apiló H, D y A en una sola prueba; se reescribió por resultado (12 pruebas por método).
- **Método aditivo:** sugirió truncar probabilidades negativas a 0, lo que rompe la suma a 1; se anula el partido (NA).
- **Errores estándar:** el modelo logístico asumía filas independientes; se usaron errores robustos por clúster de partido y se desagregó  $\beta$  por resultado, lo que reveló el efecto del empate.
- **COVID-19 y Wilcoxon:** la IA atribuyó un cambio de calibración a la ausencia de público y afirmó que todas las casas diferían significativamente; ninguna de las dos afirmaciones se sostuvo al revisar los datos (remoción aleatoria e IC bootstrap).

El equipo es responsable de todo lo entregado. La bitácora completa se presenta en el Anexo A (resumen de las 21 interacciones) y en documentos/bitacora\_ia.md del repositorio.

## Referencias

- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1), 1–3.
- Buchdahl, J. (s. f.). *Football-Data.co.uk*. <https://www.football-data.co.uk/data.php>
- Congreso de la República de Colombia. (2001). *Ley 643 de 2001: Por la cual se fija el régimen propio del monopolio rentístico de juegos de suerte y azar*. Diario Oficial No. 44.300.
- Epstein, E. S. (1969). A scoring system for probability forecasts of ranked categories. *Journal of Applied Meteorology and Climatology*, 8(6), 985–987.
- Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417.
- Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378.
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3.<sup>a</sup> ed.). John Wiley & Sons.
- Murphy, A. H. (1973). A new vector partition of the probability score. *Journal of Applied Meteorology and Climatology*, 12(4), 595–600.
- Shin, H. S. (1993). Measuring the incidence of insider trading in a market for state-contingent claims. *The Economic Journal*, 103(420), 1141–1153.
- Štrumbelj, E. (2014). On determining probability forecasts from betting odds. *International Journal of Forecasting*, 30(4), 934–943.

## Anexo A. Resumen de la bitácora de uso de IA

**Tabla A1.** *Interacciones con IA registradas en documentos/bitacora\_ia.md*

| #  | Fecha (2026) | Etapas / script      | Intervención                                                                        | Resultado                          |
|----|--------------|----------------------|-------------------------------------------------------------------------------------|------------------------------------|
| 1  | 08 sep       | Planeación / rúbrica | Esquema inicial de 5 pasos; se exigió incluir Murphy, RPS y dependencia entre casas | Aceptado con modificaciones        |
| 2  | 09 sep       | config.R             | Alcance: 16 liga-temporadas y 6.080 partidos                                        | Aceptado                           |
| 3  | 11 sep       | Descarga             | Descarga automática bloqueada por la red; descarga manual a data/raw/               | Aceptado con modificaciones        |
| 4  | 12 sep       | Script 0             | Renombrado automático por Div y Date                                                | Aceptado                           |
| 5  | 14 sep       | Script 1             | Validación de 6.080 partidos; fila en blanco descartada                             | Aceptado                           |
| 6  | 15 sep       | config.R             | Guarda temporal de Pinnacle (23/07/2025)                                            | Corregido por el equipo            |
| 7  | 17 sep       | Script 2             | Márgenes negativos: agregados de mercado separados de casas reales                  | Corregido por el equipo            |
| 8  | 18 sep       | Script 2             | Prohibido truncar a 0 en el método aditivo; se anula el partido                     | Descartado y corregido             |
| 9  | 19 sep       | Script 2             | Método de Shin y convergencia de z                                                  | Aceptado con verificación          |
| 10 | 21 sep       | Script 3             | Muestra común apareada (N = 6.074)                                                  | Corregido por el equipo            |
| 11 | 22 sep       | Script 3             | Hosmer-Lemeshow por resultado (independencia)                                       | Descartado y corregido             |
| 12 | 23 sep       | Script 3             | Grados de libertad G, G - 1 y G - 2                                                 | Aceptado con ampliación            |
| 13 | 24 sep       | Script 3             | Murphy multiclasa y término intra-intervalo                                         | Aceptado con justificación         |
| 14 | 25 sep       | Script 3             | Friedman y Wilcoxon con Holm                                                        | Corregido por el equipo            |
| 15 | 26 sep       | Script 4             | Errores estándar por clúster en la pendiente $\beta$                                | Corregido por el equipo            |
| 16 | 27 sep       | Script 4             | $\beta$ por resultado y artefacto del empate                                        | Descartado y reformulado           |
| 17 | 28 sep       | Script 3             | Hipótesis de ventaja local en COVID sin respaldo                                    | Descartado; conclusión reformulada |

| #  | Fecha (2026) | Etapas / scripts      | Intervención                                                        | Resultado                   |
|----|--------------|-----------------------|---------------------------------------------------------------------|-----------------------------|
| 18 | 29 sep       | run_all.R             | Wilcoxon vs. bootstrap; búsqueda de scripts por fase                | Corregido y validado        |
| 19 | 03 oct       | Repositorios          | Comparación de los dos repositorios del equipo                      | Aceptado con modificaciones |
| 20 | 03 oct       | Estructura del Repo 1 | Integración del análisis; ejecución completa sin errores (3,01 min) | Aceptado con modificaciones |
| 21 | 03 oct       | README y .gitignore   | README actualizado; outputs/ fuera del control de versiones         | Aceptado con modificaciones |

*Nota.* La bitácora completa (prompt, respuesta, verificación y resultado de cada interacción) está en documentos/bitacora\_ia.md del repositorio.